

# 打开流体力学的一扇窗

当《流体力学基础》课学完之后，我脑海里的第一个想法不是这门课终于上完了，而是这门课怎么这么快就结束了，里面还有好多没有理解透的概念。在期末复习时，我惊叹它的系统性，感叹它的复杂性，坚信它的发展性。系统性在于这门课特别会分类和递进，分成不同的情况去研究流体特征和方程，同时又在一个方程的基础上不断完善推进；复杂性在于流体流动机理是多因素耦合的，有时候找不到理论表达式来描述，只能依赖大量实验来得到经验公式或者计算机建模模拟；发展性在于一代代科学家前赴后继，共同构建流体力学这门综合性的学科，其中还有未解决的挑战和未发现的机遇。

之后，我和更多的人相互交流彼此的想法，去观察，去思考，去实践，逐渐形成了一个相对清晰的画面。如图 1，我将流体力学分为四大部分——理论建模、实验建模、计算建模、数据驱动建模。

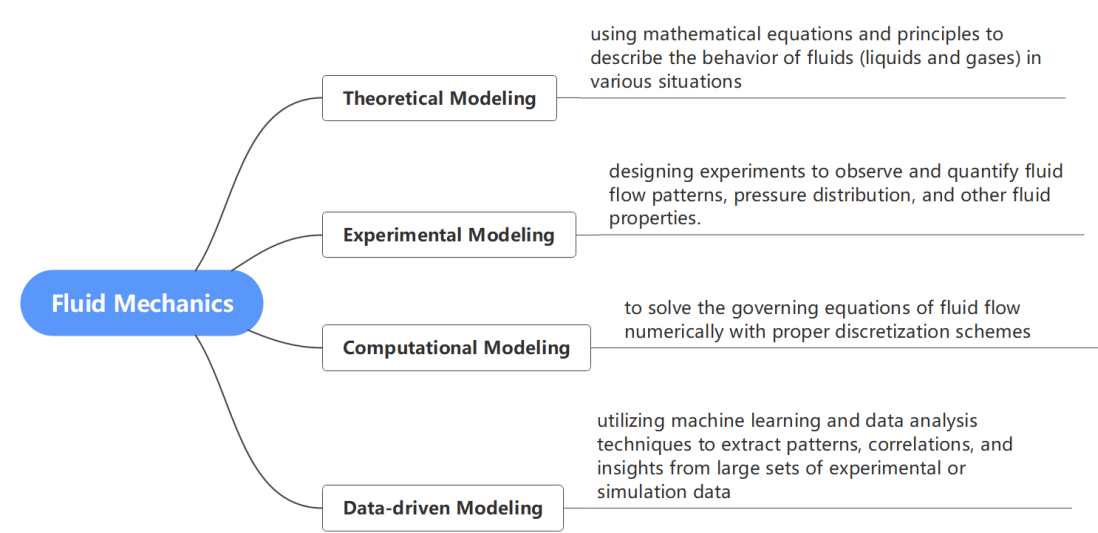


图 1 流体力学架构图

理论建模——数学方程和物理原理；实验建模——实验设计和观察量化  
计算建模——离散处理和数值计算；数据驱动建模——数据分析和机器学习

在理论建模方面，我一直在寻找一种理论能从微观角度看宏观流体的运动。当我看到元胞自动机时，豁然开朗，康威的生命游戏通过简单的单元相互作用，建立了宏观物理过程与微观离散动力学之间的联系，这不正是流体力学本质所需要的吗？元胞自动机是空间、时间、状态都离散的动力系统，特别适合研究复杂性、非线性问题。

元胞自动机的范围很广，其中的格子气自动机和流体力学最为接近。格子气自动机认为微观粒子不断碰撞进行传播的性质构成了流体运动的丰富性，1973 年，法国三位科学家提出 HPP 模型；1986 年，法国和美国三位科学家提出 FHP 模型，提高了仿真的精度；在 20 世纪 90 年代中后期，格子玻尔兹曼方法（LBM）创造性地结合了元胞自动机思想和玻尔兹曼方程，从微观的碰撞概率推导出宏观参数，将粘性理解为碰撞的弛豫时间，能够快于 CFD 完成流体运动的仿真。随着机器学习和深度学习的蓬勃发展，元胞神经网络由此诞生，进一步提高仿真速度和精度。

元胞自动机虽然从原理上、计算速度上都优于 CFD，但是寻找单元相互作用规则的过程往往凭直觉，缺乏理论构造的流程。不过我们仍赞叹元胞自动机建模的魅力，至少看到了流体本质的曙光。

在数据驱动建模方面，许多前辈将自己的思想和方法凝练成论文成果，如图 2，一部分学者在自己的科研实践中运用机器学习的方法来实现最优化；另一部分学者则运用已有的科研条件去建构智能流体的未来，发挥它存在的价值和意义。

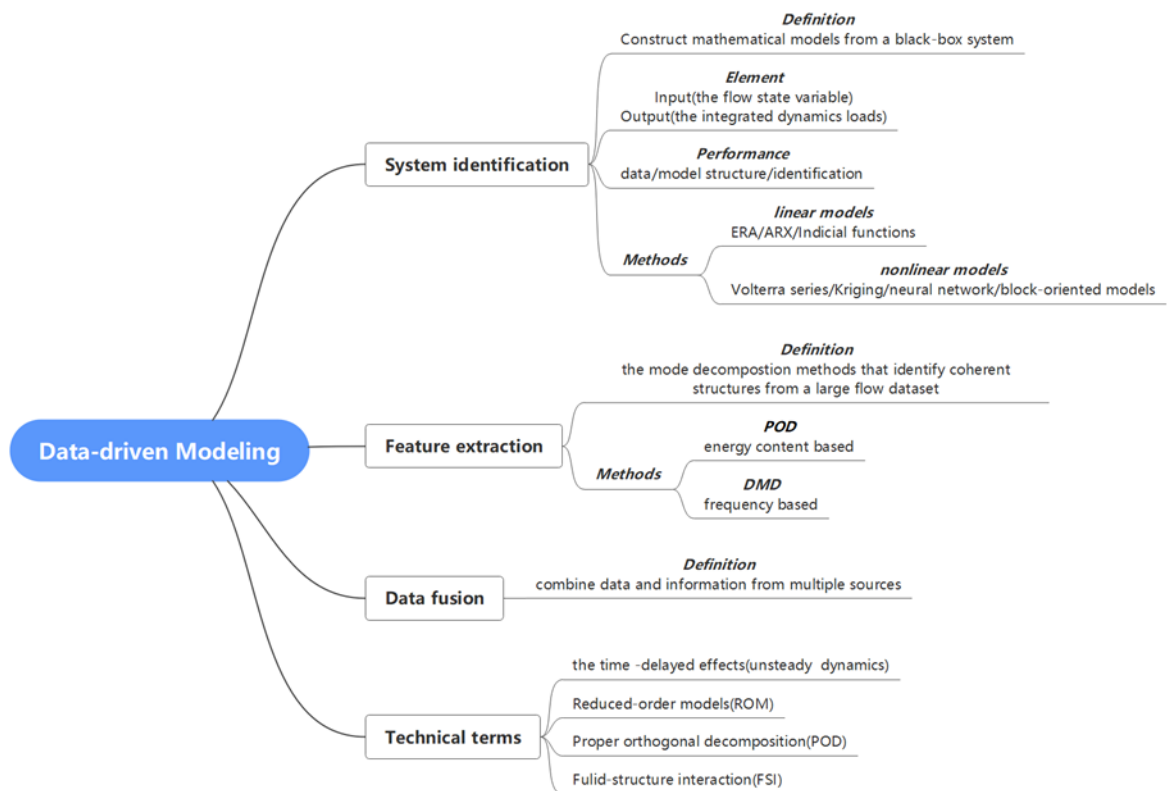


图 2 数据驱动建模架构图

- 1、System identification 建立黑箱系统，得到输入与输出的关系
- 2、Feature extraction 成分分析，数据降维，简化计算
- 3、Data fusion 得到高保真数据

## 1. ML for CFD&AI for FM 之所以能存在并且不断发展的原因？

从趋势上看，AI 在全行业的落地应用是大势所趋，从数据中获得认识和可操作的信息已经成为一种新的科学探究模式，也是一种商业机会。我们可以与 20 世纪 40 年代和 50 年代数值方法的发展相比较，流体力学将从数值算法中获益，反过来提出的挑战，可能进一步推进这些算法，补充人类的理解和工程直觉，现在利用数据驱动的学习算法解决流体动力学方程也是同样的模式。

从问题上看，仿真和实验对于迭代优化来说是昂贵的，而且仿真对于实时控制来说通常太慢。因此，人们投入大量降阶模型，以少量的成本捕获基本的流动控制，而 ML 可以提供一个简洁的框架来为流

体力学的发展提供一个新的途径，同时也在反向审视流体力学已有的经验规律。

## **2.ML for CFD&AI for FM 的不足和待发展的方向？**

我们要平衡对 ML 能力的兴奋激动和它在流体力学中的应用之间的辩证关系，目前 ML 的应用没有得到普遍认可的最大不足来自它本身的收敛性、可解释性、泛化性的问题。

其中对于可解释性问题，PINN(Physics-informed Neural Network)或许是一个不错的选择。将流体控制方程集成到神经网络中，并使用来自控制方程的残差项来构造损失函数，由该项作为惩罚项来限制可行解的空间。

俄国哲学家赫尔岑说过：“科学的事业就是使一切存在物都上升为思想。”我不时也在想有没有可能流体力学的尽头也许就是哲学呢？现有的流体力学知识基本上都是宏观描述，对于微观本质的阐述很少。因此我们需要发现微观与宏观的某种更深刻联系，不光以方程的因果思维和相关的概率思维，可能是一种新的世界观和方法论。

### **参考文献：**

- [1] Brunton, S. L., Noack, B. R., & Koumoutsakos, P. (2020). Machine Learning for Fluid Mechanics. *Annual Review of Fluid Mechanics*, 52(1), 477-508.
- [2] Kou J, Zhang W, Data-driven modeling for unsteady aerodynamics and aeroelasticity, *Progress in Aerospace Sciences*, 2021, 125: 100725
- [3] 张宏军. 物理系统的元胞自动机模拟[D].合肥工业大学,2006.